

Estrategias de Ingeniería de Datos para la Validación y Limpieza Automatizada en Flujos RPA

Pedro Antonio Vargas Ruiz

Facultad de Ingenierías y Arquitectura

Universidad Técnica Particular de Loja (UTPL)

Ingeniería en Ciencias de la Computación / Ingeniería de Datos
Loja, Ecuador

Resumen—El presente artículo desarrolla un estado del arte sobre las estrategias de Ingeniería de Datos aplicadas a la validación y limpieza automatizada de información dentro de flujos de Automatización Robótica de Procesos (RPA), y lo contrasta con un caso real de implementación sobre el macroentorno ecuatoriano. Se describe la necesidad que motivó el proyecto, las fuentes públicas utilizadas (Banco Central del Ecuador y Ministerio de Educación), la metodología de trabajo por capas Bronce-Silver-Gold, y las herramientas empleadas (Python, la librería Pandas, SQLite, PyCharm, Oracle y Power BI). Se examinan los principales marcos de calidad de datos, las técnicas de perfilado y detección de anomalías, y su integración dentro de arquitecturas ETL/ELT que anteceden a la ejecución de los robots o al consumo analítico. A través de la revisión de trabajos recientes y de la experiencia propia del proyecto, se documenta cómo la limpieza previa de los datos determinó la fiabilidad de los resultados obtenidos en un tablero de Power BI con tres vistas de análisis macroeconómico. Finalmente, se plantea una prospectiva sobre la convergencia entre RPA, Aprendizaje Automático y gobernanza de datos.

Palabras Clave—Ingeniería de Datos, RPA, Validación de Datos, Limpieza de Datos, Calidad de Datos, ETL, Arquitectura Bronce-Silver-Gold, Power BI.

I. INTRODUCCIÓN

La adopción masiva de la Automatización Robótica de Procesos (RPA) en organizaciones públicas y privadas ha evidenciado que el mayor riesgo operativo de los robots de software no reside en la lógica de orquestación, sino en la calidad de los datos que consumen. Un bot capaz de ejecutar miles de transacciones por hora puede propagar errores a la misma velocidad si los datos de entrada contienen inconsistencias, duplicados o formatos heterogéneos (Costa, Mamede, & Silva, 2022).

En este contexto, la Ingeniería de Datos deja de ser un componente periférico y se convierte en un requisito habilitante para la automatización confiable. La construcción de tuberías (pipelines) de validación previas a la ejecución de los robots permite anticipar fallos, reducir excepciones no controladas y disminuir la intervención humana correctiva (Elsayed, Abb, Sander, & Rehse, 2023).

Esta problemática no es exclusiva del sector empresarial privado: los organismos públicos ecuatorianos publican información macroeconómica y educativa en formatos heterogéneos, con nombres de provincias inconsistentes, celdas vacías y estructuras que cambian de un año a otro. Ante esta necesidad concreta, el presente trabajo nace de un proyecto propio en el que se construyó un pipeline de datos para depurar y consolidar información del Banco Central del Ecuador (BCE) y del Ministerio de Educación (MINEDUC/AMIE), con el fin de obtener información confiable para el análisis del macroentorno nacional. La experiencia adquirida en dicho proyecto —contada a lo largo de este artículo como un caso de estudio— sirve de hilo conductor para revisar, a la par, el estado del arte sobre validación y limpieza automatizada de datos.

El documento se organiza de la siguiente manera: la Sección II presenta el marco conceptual y los trabajos relacionados; la Sección III describe la metodología, las fuentes y las herramientas utilizadas en el proyecto; la Sección IV narra el caso de estudio y los resultados

obtenidos; la Sección V discute tendencias futuras; y la Sección VI presenta las conclusiones.

II. MARCO CONCEPTUAL

II-A. RPA como Consumidor Crítico de Datos

A diferencia de los sistemas transaccionales tradicionales, los robots de software interactúan con interfaces gráficas y documentos semiestructurados, por lo que carecen de mecanismos nativos de tipificación estricta de datos. Plattfaut y Borghoff (2022) señalan que buena parte de la literatura sobre RPA se ha concentrado en la adopción organizacional, dejando en segundo plano la robustez de los datos de entrada como factor determinante del éxito del proyecto.

II-B. Dimensiones de Calidad de Datos

Las dimensiones de exactitud, completitud, consistencia, actualidad y unicidad constituyen el marco de referencia más citado para evaluar conjuntos de datos antes de su ingestión (Ehrlinger, Rusz, & Wöß, 2022). Ridzuan, Idrus y Mahdin (2024) amplían esta taxonomía para escenarios de datos masivos, destacando la necesidad de reglas de validación adaptativas cuando las fuentes cambian de esquema con frecuencia, situación habitual en portales y sistemas legados que alimentan a los robots, y que se observó también en los archivos históricos del BCE utilizados en este proyecto.

II-C. Validación en Tiempo de Ejecución y Perfilado

El perfilado de datos (data profiling) permite caracterizar estadísticamente un conjunto de datos —rangos, nulos, cardinalidad— antes de definir reglas de limpieza. Rangineni (2023) argumenta que los pipelines de aprendizaje automático y de automatización comparten el mismo cuello de botella: la ausencia de validación sistemática provoca degradación silenciosa del rendimiento, un fenómeno igualmente aplicable a los flujos RPA cuando los robots reciben datos fuera de los rangos esperados sin mecanismos de alerta temprana.

II-D. Arquitectura por Capas como Marco de Referencia

La organización de los datos en capas Bronce, Silver y Gold —popularizada en arquitecturas tipo Lakehouse— constituye un marco práctico para escalar la validación de calidad de forma incremental. La capa Bronce conserva la fuente original sin modificaciones, permitiendo auditar cualquier corrección posterior; la capa Silver aplica las reglas de tipificación, deduplicación y normalización propias de la Ingeniería de Datos; y la capa Gold entrega vistas ya agregadas y confiables, listas para consumo por bots RPA o herramientas de inteligencia de negocio (Foidl et al., 2024). Este enfoque por capas resulta especialmente útil cuando las fuentes provienen de organismos públicos con formatos heterogéneos, como ocurre con los datos macroeconómicos y educativos abiertos en Ecuador.

Desde la perspectiva de los flujos RPA, adoptar una arquitectura por capas permite separar responsabilidades: el robot deja de encargarse simultáneamente de extraer, limpiar e interpretar la información, y pasa a consumir exclusivamente datos ya certificados en la capa Gold. Esta separación reduce la complejidad de la lógica del bot, disminuye la probabilidad de excepciones en tiempo de ejecución y facilita la trazabilidad de cualquier anomalía hasta la etapa del pipeline donde se originó, en línea con los principios de gobernanza de datos discutidos por Priestley, O'Donnell y Simperl (2023).

II-E. Plataformas y Herramientas de Automatización RPA

Además de los marcos conceptuales de calidad de datos, es necesario considerar las plataformas sobre las que se ejecutan los robots de software, dado que su capacidad de conexión con fuentes de datos externas condiciona directamente qué tan temprano puede detectarse un error. Herramientas como UiPath y Power Automate ofrecen conectores nativos hacia bases de datos, hojas de cálculo y APIs, pero delegan en el desarrollador la responsabilidad de definir las reglas de validación previas al procesamiento. Iordache y Ștefănița (2025) documentan precisamente el uso de UiPath para la extracción y validación de datos

clínicos, evidenciando que la robustez del resultado depende más del diseño del flujo de validación que de la plataforma de automatización elegida.

Trabajos Relacionados

II-F. Adopción y Madurez de RPA

La revisión sistemática de Costa, Mamede y Silva (2022) identifica que la falta de estandarización de datos de entrada es una de las principales causas de fallo en proyectos de RPA a gran escala, incluso por encima de factores tecnológicos. En una línea similar, Bhardwaj (2023) revisó más de noventa estudios sobre RPA en operaciones empresariales y concluyó que los procesos con mayor tasa de automatización exitosa son aquellos que incorporan capas de limpieza y normalización previas a la ejecución del bot.

II-G. Validación Automatizada en Sectores Regulados

Elsayed et al. (2023) documentan la aplicación de RPA para la validación de software en industrias reguladas, demostrando que los robots pueden ejecutar comprobaciones de cumplimiento normativo de forma reproducible cuando los datos de entrada han sido previamente saneados mediante reglas declarativas. De manera análoga, Iordache y Ștefănița (2025) desarrollaron un sistema basado en UiPath para la extracción y validación automatizada de datos clínicos, evidenciando reducciones significativas en el tiempo de procesamiento y en la tasa de errores frente al tratamiento manual.

II-H. Marcos de Calidad de Datos en Pipelines de Ingeniería

Foidl, Golendukhina, Ramler y Felderer (2024) analizan los factores que inciden en la calidad de las tuberías de datos, identificando la ausencia de pruebas automatizadas como la causa raíz más recurrente de errores en producción. Priestley, O'Donnell y Simperl (2023) complementan esta perspectiva señalando que los requisitos de calidad de datos deben definirse desde etapas tempranas del ciclo de vida del pipeline, principio directamente trasladable a la construcción de flujos RPA que dependen de fuentes externas heterogéneas.

Cuadro I
COMPARATIVA DE ENFOQUES DE VALIDACIÓN DE DATOS EN FLUJOS AUTOMATIZADOS

Enfoque	Etapas del Pipeline	Aporte Clave
Perfilado de Datos	Pre-ingestión	Caracteriza rangos, nulos y cardinalidad antes de definir reglas de limpieza (Rangineni, 2023).
Validación Declarativa	ETL / Pre-RPA	Aplica reglas de negocio reproducibles antes de la ejecución del bot (Elsayed et al., 2023).
Monitoreo Continuo de Calidad	Post-ejecución	Detecta degradación progresiva de la calidad y dispara alertas (Foidl et al., 2024).

III. METODOLOGÍA, FUENTES Y HERRAMIENTAS

III-A. La Necesidad y las Fuentes de Datos

El punto de partida del proyecto fue una necesidad concreta: no existía, dentro del entorno de trabajo, una fuente única y confiable que permitiera analizar el macroentorno ecuatoriano combinando indicadores económicos y educativos. La información disponible estaba dispersa en boletines del Banco Central del Ecuador (BCE) —con series históricas del Producto Interno Bruto (PIB) desde 1965— y en registros del Ministerio de Educación (MINEDUC/AMIE) sobre bachilleres graduados, además de registros de empresas activas por provincia. Cada fuente llegaba en formato distinto (hojas de cálculo con encabezados desalineados, celdas combinadas y nombres de provincias escritos de forma inconsistente), por lo que la primera tarea metodológica consistió en definir cómo ingerir estas fuentes sin perder trazabilidad respecto al dato original.

III-B. Metodología de Trabajo por Capas

Se adoptó una metodología incremental de tres etapas, replicando el marco Bronce-Silver-Gold descrito en la Sección II-D. Primero se definieron reglas de ingestión para volcar cada fuente cruda en la capa Bronce sin alterarla. Después, en la capa Silver, se documentaron y aplicaron reglas de limpieza específicas por fuente: tipificación de columnas numéricas, eliminación de duplicados, normalización de nombres de provincias a un catálogo único, y tratamiento explícito de valores nulos. Finalmente, en la capa Gold, se diseñaron consultas de agregación orientadas directamente a las preguntas analíticas del proyecto (evolución del PIB, distribución de empresas por provincia, relación entre bachilleres y empresas), de modo que cada vista Gold respondiera a una necesidad de negocio concreta y no simplemente replicara la estructura original de la fuente.

III-C. Herramientas Empleadas

El desarrollo del pipeline se realizó en Python, utilizando el entorno de desarrollo PyCharm para organizar el código en módulos independientes por fuente de datos. La limpieza y transformación de las tablas se apoyó fuertemente en la librería Pandas, que permitió leer los archivos originales, aplicar funciones de normalización, reestructurar datos de formato ancho a formato largo, y validar tipos de datos antes de persistirlos. Para el almacenamiento intermedio de las capas Silver y Gold se utilizó SQLite, por su ligereza y facilidad de integración directa con scripts de Python sin requerir un servidor de base de datos independiente; adicionalmente, se evaluó Oracle como motor de base de datos relacional para escenarios donde se requeriría escalar el pipeline a un entorno institucional con mayor concurrencia y control de accesos. Finalmente, sobre las vistas Gold ya validadas se construyó el tablero de análisis en Power BI, configurado en modo DirectQuery para reflejar cambios en los datos sin necesidad de recargas manuales completas.

IV. CASO DE ESTUDIO
Del Dato Crudo al Tablero

IV-A. Construcción de la Arquitectura Bronce-Silver-Gold

La historia del proyecto puede resumirse en tres momentos. En el primero, los archivos del BCE y del MINEDUC se cargaron tal cual a la capa Bronce, sin ninguna transformación, únicamente para dejar evidencia del dato original ante cualquier auditoría posterior. En el segundo momento, al intentar cruzar la información de empresas activas con los bachilleres graduados por provincia, aparecieron los primeros problemas reales: una misma provincia se encontraba escrita de más de una forma en distintas fuentes, existían filas duplicadas heredadas de años de recopilación manual, y varios campos numéricos venían como texto. Resolver estos problemas exigió construir explícitamente la capa Silver, con funciones de Python y Pandas dedicadas a tipificar campos, eliminar duplicados y normalizar el catálogo de provincias a una sola versión estándar. En el tercer momento, ya con datos consistentes en SQLite, se diseñaron las vistas Gold —consultas agregadas por año y por provincia— que finalmente alimentaron el tablero de Power BI.

IV-B. Resultados Obtenidos

El resultado tangible del proyecto fue un tablero de Power BI de tres páginas. La primera página muestra el ciclo económico del PIB ecuatoriano entre 2000 y 2025, contrastando la variación porcentual anual con el tamaño real de la economía; en ella se identifica 2020 como el año de mayor contracción (-7.8%), coincidente con el inicio de la pandemia, seguido de una recuperación sostenida entre 2021 y 2023. La segunda página presenta la distribución de empresas activas por provincia, evidenciando que Guayas y Pichincha concentran cerca del 69% del total nacional de empresas activas, muy por encima del resto de provincias. La tercera página relaciona el número de bachilleres graduados de tercero de bachillerato con el número de empresas activas por provincia, mostrando que en la mayoría de provincias el número de graduados supera al de empresas activas, lo que sugiere una posible brecha entre la oferta de talento joven y la demanda laboral formal fuera de los dos polos económicos principales.

Estos resultados solo fueron interpretables de forma correcta gracias a la limpieza realizada en la capa Silver. En una prueba preliminar en la que se intentó construir las mismas visualizaciones directamente sobre los datos Bronce, los totales por provincia aparecían duplicados o subestimados debido a los nombres de provincia inconsistentes, lo que habría llevado a conclusiones erróneas sobre la concentración empresarial del país. Esta comparación práctica confirma, en un caso real ecuatoriano, lo señalado por Foidl et al. (2024): la calidad del resultado analítico depende directamente de la calidad de los datos que llegan a la capa de consumo, no de la sofisticación de la herramienta de visualización.

IV-C. Evidencia Visual: Vista del PIB en Power BI

La Figura 1 muestra la vista Gold correspondiente al ciclo económico del PIB, ya construida y publicada en Power BI a partir de los datos saneados en la capa Silver. El gráfico combina un eje de barras con la variación porcentual anual del PIB, clasificada por color según el tipo de ciclo (contracción, crecimiento moderado o crecimiento fuerte), y una línea que representa el tamaño real de la economía en miles de millones de dólares entre 1965 y 2024. Esta doble representación permite identificar de un vistazo tanto los años de crisis —como 1999 y 2020— como la tendencia de crecimiento sostenido de largo plazo, algo que habría sido mucho más difícil de leer directamente sobre la tabla cruda del Banco Central del Ecuador.




Fig. 1. PIB real anual y variación con clasificación del ciclo económico (Power BI, elaboración propia).

V. TENDENCIAS Y FUTURO

A partir de la revisión teórica y de la experiencia del proyecto, se identifican tres vectores de evolución:

- 1) *Validación Predictiva basada en Aprendizaje Automático*: modelos capaces de anticipar registros anómalos antes de que el robot o el pipeline los procese, reduciendo la dependencia de reglas estáticas (Rangineni, 2023).
- 2) *Gobernanza de Datos Integrada al Ciclo del Pipeline*: incorporación de catálogos y linaje de datos que permitan auditar el origen de cada corrección aplicada entre capas, en línea con los marcos de calidad discutidos por Foidl et al. (2024).
- 3) *Auto-remediación de Excepciones*: flujos capaces de corregir automáticamente inconsistencias menores y escalar únicamente los casos ambiguos a revisión humana (Human-in-the-Loop), reduciendo el reproceso manual documentado por Iordache y Ștefănița (2025).

En el contexto específico de este proyecto, el siguiente paso natural sería automatizar la actualización periódica de las capas Bronce y Silver mediante un mecanismo tipo watchdog que detecte nuevos archivos publicados por el BCE o el MINEDUC y dispare el pipeline de limpieza sin intervención manual, acercando el proyecto a un flujo RPA completo en el que el tablero de Power BI se mantenga siempre actualizado sin reprocesos manuales.

VI. CONCLUSIONES

La revisión del estado del arte confirma que la sostenibilidad de los flujos RPA y de los pipelines analíticos depende en gran medida de la madurez de la Ingeniería de Datos que los sustenta. La validación y limpieza automatizada, lejos de ser una etapa preparatoria menor, constituye el mecanismo que determina la confiabilidad, la trazabilidad y la escalabilidad de la automatización.

El caso de estudio desarrollado corrobora esta premisa con datos reales del Ecuador: la arquitectura por capas Bronce-Silver-Gold, construida con Python, Pandas y SQLite, y ejecutada sobre fuentes del BCE y del MINEDUC, permitió obtener vistas Gold confiables sobre las cuales se construyó un tablero funcional en Power BI. Los tres resultados obtenidos —el ciclo económico del PIB, la distribución de empresas activas por provincia y la relación entre bachilleres graduados y empresas activas— solo fueron interpretables correctamente porque la limpieza y validación se ejecutaron antes de llegar a la capa de visualización, lo que valida en un caso real ecuatoriano las conclusiones reportadas en la literatura revisada.

REFERENCIAS

- Bhardwaj, V. (2023). A systematic review of robotic process automation in business operations: Contemporary trends and insights. *Journal of Intelligent Systems and Control*, 2(3), 153–169. <https://doi.org/10.56578/jisc020304>
- Costa, S. A. S., Mamede, H. S., & Silva, M. M. (2022). Robotic Process Automation (RPA) adoption: A systematic literature review. *Engineering Management in Production and Services*, 14(2), 1–12. <https://doi.org/10.2478/emj-2022-0012>
- Ehrlinger, L., Rusz, E., & Wöß, W. (2022). A survey of data-quality measurement and monitoring tools. *Frontiers in Big Data*, 5. <https://doi.org/10.3389/fdata.2022.850611>
- Elsayed, N., Abb, L., Sander, H., & Rehse, J. R. (2023). Automating computer software validation in regulated industries with Robotic Process Automation. In *Business Process Management: Blockchain, Robotic Process Automation and Educators Forum (BPM 2023)*, LNBIP vol. 491. Springer. https://doi.org/10.1007/978-3-031-43433-4_9
- Foidl, H., Golendukhina, V., Ramler, R., & Felderer, M. (2024). Data pipeline quality: Influencing factors, root causes, and processing problem areas. *Journal of Systems and Software*, 210. <https://doi.org/10.1016/j.jss.2023.111946>
- Iordache, O. C., & Ștefănița, S. A. (2025). Understanding the role of Robotic Process Automation in healthcare. *Applied Medical Informatics*, 47(Suppl. 1).
- Plattfaut, R., & Borghoff, V. (2022). Robotic process automation: A literature-based research agenda. *Journal of Information Systems*, 36(2), 173–191.
- Priestley, M., O'Donnell, F., & Simperl, E. (2023). A survey of data quality requirements that matter in ML development pipelines. *Journal of Data and Information Quality*, 15(1), Article 11.
- Rangineni, S. (2023). An analysis of data quality requirements for machine learning development pipelines frameworks. *International Journal of Computer Trends and Technology*, 71(8), 16–27. <https://doi.org/10.14445/22312803/IJCTT-V71I8P103>
- Ridzuan, N., Idrus, M., & Mahdin, H. (2024). A review of data-quality dimensions for big data. *IEEE Access*, 12, 11258–11275. <https://doi.org/10.1109/ACCESS.2024.3353678>