

Ingeniería de Datos para LLMs: El Desafío de los Petabytes en la Era de la Inteligencia Artificial Generativa

Pedro Vargas

Facultad de Ingenierías y Arquitectura

Universidad Técnica Particular de Loja (UTPL)

Ingeniería en Ciencias de la Computación — 4to Ciclo, Practicum 1.2

Docente: Ing. Nelson Piedra

Loja, Ecuador

Resumen—El éxito de la inteligencia artificial generativa depende menos de la arquitectura del modelo y más de la calidad del combustible que lo alimenta: los datos. El presente documento analiza la ingeniería de datos para modelos de lenguaje de gran escala (LLMs) a escala de petabytes, explorando los procesos críticos de recolección, limpieza y procesamiento de información no estructurada. Se examinan las estrategias más eficientes para maximizar el manejo de información minimizando el consumo de recursos, y se evalúan las tecnologías de almacenamiento de alto rendimiento que permiten procesar billones de tokens de manera eficiente.

Index Terms—Ingeniería de Datos, LLM, Petabytes, Tokenización, Pipelines, Soberanía de Datos, IA Generativa.

I. Introducción

En la actualidad, la inteligencia artificial ha desplazado su foco desde la creación de modelos de mayor complejidad hacia el recurso que verdaderamente determina su rendimiento: los datos. Si las unidades de procesamiento gráfico (GPUs) constituyen el motor de esta revolución tecnológica, los datos representan su combustible; sin información de calidad, el potencial computacional se ve drásticamente limitado.

La presente investigación examina la transición desde el simple almacenamiento de archivos hacia la construcción de infraestructuras sólidas capaces de preparar datos para aplicaciones de inteligencia artificial. En el contexto de instancias tecnológicas como la Dirección General de Tecnologías de la Información y Transformación Digital (DGTITD), este enfoque resulta de especial relevancia, pues la mera retención de información ya no es suficiente; se requiere su procesamiento mediante pipelines que habiliten la creación de modelos propios, soberanos y seguros.

Llevar estos principios a la práctica a escala de petabytes plantea interrogantes fundamentales: la eliminación de datos duplicados de la web sin comprometer la calidad educativa; la selección de infraestructuras de cómputo distribuido que prevengan cuellos de botella entre CPU y GPU durante el preprocesamiento; y el impacto de la soberanía de datos y las leyes de localización en el diseño global de la ingeniería de datos.

II. Marco Conceptual

A fin de delimitar el alcance de esta investigación, se presentan a continuación las definiciones fundamentales que articulan el campo de la ingeniería de datos aplicada a modelos de lenguaje de gran escala.

II-A. Tokenización

Proceso mediante el cual se fragmenta el texto en unidades atómicas denominadas tokens, procesables numéricamente por el modelo. Constituye el primer eslabón en la cadena de preprocesamiento de cualquier corpus textual destinado al entrenamiento de un LLM.

II-B. Dato No Estructurado

Información que no reside en una base de datos relacional tradicional. Comprende textos, imágenes, audio y video, y representa la mayor proporción del volumen de datos disponibles en entornos reales de entrenamiento de modelos de inteligencia artificial.

II-C. Petabytes y Common Crawl

Un petabyte equivale a 1.000 terabytes (TB), o a 1.024 TB en el sistema binario, y constituye la unidad de referencia para los volúmenes de datos utilizados en el entrenamiento de los grandes modelos actuales. Common Crawl es el archivo público de la web a esta escala que sirve como materia prima de referencia para numerosos proyectos de IA.

II-D. MinHash y Deduplicación

MinHash es un algoritmo probabilístico que genera firmas compactas para estimar la similitud de Jaccard entre dos conjuntos de datos, convirtiéndose en herramienta esencial para la detección y eliminación eficiente de contenido duplicado a escala masiva en corpus de entrenamiento.

II-E. LLMs

Los Modelos de Lenguaje de Gran Tamaño (LLMs, por sus siglas en inglés) son sistemas de inteligencia artificial entrenados para comprender, generar y manipular lenguaje humano de forma coherente.

III. Trabajos Relacionados

La investigación contemporánea, tanto en el ámbito académico como en la industria, ha desplazado su foco desde la maximización del volumen de datos

hacia la aplicación de estrategias de refinamiento masivo orientadas a mejorar la eficiencia real de los modelos. A continuación se describen los proyectos que sirven de base para el presente análisis.

III-A. *Hugging Face: FineWeb y FineWeb2*

FineWeb constituye un ejemplo paradigmático de cómo filtrar datos provenientes de la web —específicamente de Common Crawl— mediante clasificadores de calidad. Los resultados evidencian que un dataset correctamente depurado puede superar en rendimiento a uno diez veces mayor con alta proporción de ruido. Con FineWeb2, esta metodología se ha extendido a más de 1.000 idiomas (Hugging Face, 2025).

III-B. *Apple & University of Washington: DCLM*

El marco DataComp-LM (DCLM) establece una metodología estandarizada para la curación de datos de entrenamiento. Su enfoque demuestra que la aplicación de modelos de clasificación como FastText es determinante para que el LLM alcance un desempeño destacado en pruebas de razonamiento lógico (Li et al., 2024).

III-C. *Meta: Llama 3.1*

Durante el desarrollo del modelo Llama 3.1 de 405 mil millones de parámetros, Meta AI implementó la técnica de “annealing” (recocido). En la fase final del entrenamiento, se priorizó la incorporación de datos técnicos y científicos de alta calidad para potenciar la capacidad lógica del modelo (Meta AI, 2024).

IV. **Herramientas y Tecnologías**

El ecosistema de la ingeniería de datos ha experimentado una transformación profunda. La clave actual reside en la orquestación de recursos heterogéneos: la combinación eficiente de la potencia de las CPUs y las GPUs. A continuación se presentan las tecnologías que lideran el manejo de petabytes destinados a inteligencia artificial, organizadas en el Cuadro I.

Cuadro I
Comparativa de Tecnologías Líderes en Ingeniería de Datos para IA

Herramienta	Enfoque Principal	Diferenciador Técnico
Ray	Orquestación IA	Soporte nativo para cargas mixtas CPU/GPU con baja latencia; reduce costos hasta 30× frente a Spark en inferencia por lotes (Moritz et al., 2018).
Apache Spark	ETL Tradicional	Estándar para datos estructurados y procesos Batch; menor flexibilidad para patrones de IA modernos en comparación con Ray.

WEKA NeuralMesh	Almacenamiento	Sistema de archivos paralelo con latencia de microsegundos; evita tiempos de inactividad en GPUs durante el procesamiento masivo (WekaIO, 2025).
Microsoft Presidio	Privacidad/PII	Detección y anonimización automática de datos personales (PII) a gran escala para cumplimiento normativo internacional (Microsoft, 2023).
Lance / Zarr	Formatos de Datos	Sucesores de Parquet diseñados para acceso aleatorio rápido y manejo eficiente de embeddings para LLMs (Apache Software Foundation, 2024).

IV-A. *Análisis de Rendimiento*

La comparación entre herramientas revela diferencias nítidas: Apache Spark mantiene su supremacía en el análisis de inteligencia de negocios (BI) tradicional, mientras que Ray se ha consolidado como la opción preferida para cargas de trabajo de inteligencia artificial. Su capacidad para gestionar actores con estado y su eficiencia en la inferencia por lotes pueden reducir los costos hasta 30 veces en comparación con Spark, lo cual representa un cambio radical en cualquier presupuesto de infraestructura (Moritz et al., 2018).

Otro punto crítico es el del almacenamiento. Los sistemas convencionales, como NFS, generan cuellos de botella que mantienen las GPUs inactivas, desperdiciando recursos de cómputo. Soluciones como WEKA NeuralMesh o NVMe-oF eliminan estas restricciones, permitiendo que el almacenamiento opere con latencias próximas a las de la memoria RAM y aprovechando cada ciclo de procesamiento de manera óptima (WekaIO, 2025).

V. **Tendencias y Futuro**

El análisis prospectivo para el período 2026-2029 indica una convergencia hacia la automatización total de los procesos de curación de datos, articulada en tres vectores dominantes.

V-A. *Ingeniería de Datos Agéntica*

El empleo de agentes de inteligencia artificial para inspeccionar, limpiar y proponer transformaciones sobre los datos de forma autónoma se proyecta como la norma en el corto plazo. Se estima que hacia finales de 2026, el 40 % de las aplicaciones empresariales integrarán agentes de este tipo en sus flujos de trabajo.

V-B. *Soberanía y Localización de Datos*

Las regulaciones globales, en particular la Ley de Inteligencia Artificial de

la Unión Europea, impondrán la obligación de procesar y almacenar datos dentro de fronteras geográficas específicas. Este marco normativo impulsará infraestructuras de “IA Soberana” que priorizan la residencia del dato sobre los modelos de centralización (European Parliament, 2024).

V-C. *Datos Sintéticos y “AI-Ready Data”*

Ante el agotamiento de los datos web públicos de calidad, los modelos se entrenarán progresivamente sobre datos generados y evaluados por otros modelos, lo que exigirá pipelines de validación de alta rigurosidad para prevenir el colapso por retroalimentación. Paralelamente, la inversión se desplazará del desarrollo de modelos hacia la construcción de fundaciones de datos semánticamente ricos y confiables, consideradas el tema central de la ingeniería de datos para 2026.

VI. Conclusiones

El rendimiento de los sistemas de inteligencia artificial no depende exclusivamente de la calidad del algoritmo, sino de la solidez de los sistemas de almacenamiento —como NVMe-oF— y del cómputo distribuido con plataformas como Ray. Una infraestructura deficiente condena a las GPUs a operar por debajo de su capacidad real, desperdiciando recursos de cómputo y capital.

El paradigma del entrenamiento masivo e indiscriminado ha quedado superado. La aplicación de filtros inteligentes y criterios de curación rigurosos permite que modelos de menor tamaño superen en rendimiento a modelos significativamente más grandes entrenados con datos de baja calidad, con el consecuente ahorro en tiempo de cómputo y recursos de infraestructura.

El manejo de petabytes de datos no estructurados implica riesgos normativos y éticos que no pueden soslayarse. La implementación de procesos automáticos de desidentificación mediante herramientas como Microsoft Presidio resulta indispensable para garantizar el cumplimiento de la legislación internacional vigente y la protección de los activos de datos institucionales (Microsoft, 2023).

Referencias

- Apache Software Foundation. (2024). *Apache Parquet documentation*. <https://parquet.apache.org/docs/>
- European Parliament. (2024). *Regulation (EU) 2024/1689 of the European Parliament and of the Council laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Official Journal of the European Union. https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=OJ:L_202401689
- Hugging Face. (2025). *FineWeb2: One pipeline to scale them all — Adapting pre-training data processing to every language*. <https://huggingface.co/spaces/HuggingFaceFW/blogpost-fineweb2>
- Li, J., Fang, A., Smyrnis, G., Ivgi, M., Jordan, M., Gadre, S., Bansal, H., Guha, E., Keh, S., Arora, K., Garg, S., Xin, R., Muennighoff, N., Heckel, R., Mercat, J., Park, J., Taori, R., Dave, M., Xia, P., ... Schmidt, L. (2024). *DataComp-LM: In search of the next generation of training sets for language models*. arXiv. <https://arxiv.org/abs/2406.11794>
- Meta AI. (2024). *The Llama 3 herd of models*. arXiv. <https://arxiv.org/abs/2407.21783>
- Microsoft. (2023). *Microsoft Presidio: Data protection and de-identification SDK*. GitHub. <https://github.com/microsoft/presidio>
- Moritz, P., Nishihara, R., Wang, S., Tumanov, A., Liaw, R., Liang, E., Elibol, M., Yang, L., Paul, W., Jordan, M. I., & Stoica, I. (2018). *Ray: A distributed framework for emerging AI applications*. Proceedings of the 13th USENIX Symposium on Operating Systems Design and Implementation (OSDI), 561–577. <https://www.usenix.org/conference/osdi18/presentation/moritz>
- WekaIO. (2025). *Inference at scale: Storage as the new AI battleground*. <https://www.weka.io/resources/white-paper/ai-storage-inference/>