

Ingeniería de Datos



Carrera:

Computación

Ciclo:

4to-Practicumm 1.2

Docente:

Ing. Nelson Piedra

Estudiante:

Pedro Vargas

Ingeniería de Datos para LLMs: El Desafío de los Petabytes en la Era de la Inteligencia Artificial Generativa

1. Resumen / Abstrac

El éxito de la inteligencia artificial generativa depende menos de la arquitectura del modelo y más de la calidad del combustible que lo alimenta, es decir, los datos. Este documento analiza la ingeniería de datos para LLMs a escala de petabytes, explorando los procesos críticos de recolección, limpieza y procesamiento de información no estructurada. Se estudiará las maneras más eficientes de como tener un mayor manejo de información consumiendo la menor cantidad de recursos posibles, por ello, se evalúan las tecnologías de almacenamiento de alto rendimiento que permiten procesar billones de tokens de manera eficiente.

2. Introducción:

Hoy en día, la IA ha dejado de centrarse solo en crear modelos complejos para enfocarse en lo que realmente importa, los datos. Si pensamos en las GPUs como el motor de esta revolución, los datos son el combustible, sin información de calidad, el motor simplemente no rinde.

En esta investigación explico cómo pasar de simplemente guardar archivos a construir infraestructuras sólidas que preparen esos datos para la IA. Para una dirección tecnológica como la DGTITD, esto es vital, porque ya no basta con tener la información almacenada; hay que saber procesarla mediante tuberías de datos o pipelines para crear modelos propios, soberanos y seguros.

Sin embargo, llevar esto a la práctica a una escala de petabytes plantea dudas fundamentales sobre cómo limpiar y eliminar datos repetidos de la web sin perder la

calidad educativa de la información. También toca preguntarse qué infraestructuras de cómputo distribuido son mejores para evitar cuellos de botella entre la CPU y la GPU durante el preprocesamiento. Finalmente, no se puede ignorar el entorno legal, por lo que analizo cómo la soberanía de los datos y las leyes de localización están impactando el diseño de la ingeniería de datos a nivel global.

3. Marco Conceptual

- **Tokenización:** Proceso de fragmentar el texto en unidades atómicas (tokens) que el modelo puede procesar numéricamente.
- **Dato No Estructurado:** Información que no reside en una base de datos relacional tradicional.
- **Petabytes:** Unidad de almacenamiento de datos masiva que equivale a 1,000 terabytes (TB) (o exactamente 1,024 TB en el sistema binario).
- **MinHash:** Algoritmo probabilístico que genera firmas compactas para estimar la similitud de Jaccard entre dos conjuntos de datos.
- **Common Crawl:** Archivo público de la web a escala de petabytes que sirve como materia prima para el entrenamiento de IAs.
- **LLMs:** Los LLMs (Large Language Models o Modelos de Lenguaje de Gran Tamaño) son un tipo de inteligencia artificial entrenada para comprender, generar y manipular lenguaje humano de forma coherente.
- **DGTITD:** Dirección General de Tecnologías de la Información y Transformación Digital.

4. Trabajos Relacionados

Hoy en día, tanto en la industria como en la academia, ya no se trata solo de meter más datos, sino de aplicar estrategias de refinamiento masivo para que los modelos sean realmente eficientes. Algunos de los proyectos que sirven de base para esta investigación son:

- **Hugging Face (FineWeb & FineWeb2):** Es un ejemplo clave de cómo filtrar datos de la web (como Common Crawl) usando clasificadores de calidad. Lo interesante aquí es que demostraron que un dataset bien limpio puede dar mejores resultados que uno diez veces más grande pero "sucio". Con FineWeb2, esto ya se está llevando a más de 1,000 idiomas (Hugging Face, 2025).
- **Apple & University of Washington (DCLM):** Con el marco DataComp-LM, establecieron una forma estándar de curar datos. Su enfoque muestra que usar modelos como FastText para filtrar la información es vital si queremos que el LLM destaque en pruebas de razonamiento lógico (Li et al., 2024).
- **Meta (Llama 3.1):** Durante el desarrollo de su modelo de 405B, usaron una técnica llamada "annealing" (o recocido). Básicamente, en la fase final del entrenamiento le dieron prioridad a datos técnicos y científicos de altísima calidad para "pulir" la capacidad lógica del modelo (Meta AI, 2024).

5. Herramientas y Tecnologías

El ecosistema para la ingeniería de datos ha cambiado muchísimo; ya no trabajamos solo con procesadores comunes. Ahora, la clave está en la orquestación de recursos heterogéneos, es decir, saber combinar de forma eficiente la potencia de las CPU y las GPU.

En mi análisis, he seleccionado las tecnologías que realmente están moviendo la aguja en el manejo de petabytes para IA:

5.1. Stack Tecnológico Principal

- **Ray (Orquestación):** Es el motor que está ganando terreno para IA. Lo que lo hace especial es su soporte nativo para cargas mixtas: puedes hacer la limpieza pesada en la CPU y pasar el entrenamiento a la GPU casi sin latencia.
- **Apache Spark (ETL Tradicional):** Sigue siendo el estándar para mover datos estructurados y procesos tipo Batch, aunque para los patrones de IA más modernos se queda un poco corto en flexibilidad comparado con Ray.
- **WEKA NeuralMesh (Almacenamiento):** Cuando manejamos volúmenes masivos, no podemos permitirnos esperas. Este sistema de archivos paralelo baja la latencia a microsegundos, evitando que las máquinas se queden inactivas.
- **Microsoft Presidio (Privacidad):** Es la herramienta que uso para el cumplimiento normativo. Me permite detectar y anonimizar datos personales (PII) de forma automática y a gran escala antes de procesar cualquier modelo (Microsoft, 2023).
- **Lance / Zarr (Formatos de Datos):** Son los sucesores de Parquet. Están diseñados específicamente para lo que necesitan los LLMs: un acceso aleatorio muy rápido y un manejo eficiente de embeddings (Apache Software Foundation, 2024).

5.2. Comparativa y Análisis de Rendimiento

En mi investigación, la diferencia entre las herramientas es clarísima: mientras Apache Spark sigue siendo imbatible para el análisis de negocios tradicional (BI), Ray se ha convertido en el preferido para la IA. Su capacidad para gestionar “actores” (estados) y su eficiencia en la inferencia por lotes puede llegar a reducir los costos

hasta 30 veces en comparación con Spark, lo cual es un cambio radical en cualquier presupuesto de infraestructura (Moritz et al., 2018).

Otro punto crítico que he identificado es el almacenamiento. Los sistemas antiguos (como NFS) generan cuellos de botella que dejan a las GPUs sin hacer nada, básicamente desperdiciando dinero y tiempo. Soluciones como WEKA o NVMe-oF permiten que el almacenamiento funcione casi como si fuera memoria RAM eliminando las trabas del sistema operativo y aprovechando cada ciclo de procesamiento al máximo (WekaIO, 2025).

6. Tendencias y Futuro

Hacia 2026-2029, el campo se dirige hacia la automatización total de la curaduría:

Ingeniería de Datos Agéntica: El uso de agentes de IA para inspeccionar, limpiar y proponer transformaciones en los datos de forma autónoma será la norma. Para finales de 2026, se estima que el 40% de las aplicaciones empresariales integrarán agentes de este tipo:

- **Soberanía y Localización:** Las regulaciones globales (como la Ley de IA de la UE) forzarán a las organizaciones a procesar y almacenar datos dentro de fronteras específicas, impulsando infraestructuras de “IA Soberana” que priorizan la residencia del dato sobre la centralización (European Parliament, 2024).
- **Datos Sintéticos de Alta Fidelidad:** Ante el agotamiento de los datos web públicos, los modelos se entrenarán cada vez más en datos generados y criticados por otros modelos, lo que requiere tuberías de validación extremadamente rigurosas para evitar el colapso del modelo por retroalimentación.

- **Enfoque en "AI-Ready Data":** La inversión se desplazará del desarrollo de modelos hacia la creación de fundaciones de datos semánticamente ricas y confiables, considerándose el tema central de la ingeniería para 2026.

7. Conclusiones

El éxito de la IA hoy no depende solo de qué tan bueno sea el algoritmo, sino de tener sistemas de almacenamiento como NVMe-oF y cómputo distribuido con Ray. Si la infraestructura no es sólida, las GPUs se quedan desperdiciadas y no trabajan al 100%.

Hoy en día ya no sirve de nada entrenar modelos con "toda la web" si la información es basura. Hoy, usar filtros inteligentes nos permite crear modelos mucho más eficientes; al final, un dataset limpio hace que un modelo pequeño rinda más que uno gigante, ahorrándonos tiempo y servidores.

Manejar petabytes de datos no estructurados es un riesgo si no se hace bien. Necesitamos procesos automáticos de desidentificación, usando herramientas como Microsoft Presidio, para cumplir con las leyes internacionales y proteger la propiedad intelectual de lo que estamos construyendo.

8. Referencias

- Hugging Face. (2025). FineWeb2: One pipeline to scale them all — Adapting pre-training data processing to every language.
<https://huggingface.co/spaces/HuggingFaceFW/blogpost-fineweb2>
- Li, J., Fang, A., Smyrnis, G., Ivgi, M., Jordan, M., Gadre, S., Bansal, H., Guha, E., Keh, S., Arora, K., Garg, S., Xin, R., Muennighoff, N., Heckel, R.,

Mercat, J., Park, J., Taori, R., Dave, M., Xia, P., ... Schmidt, L. (2024).

DataComp-LM: In search of the next generation of training sets for language models. arXiv. <https://arxiv.org/abs/2406.11794>

- Meta AI. (2024). The Llama 3 herd of models. arXiv. <https://arxiv.org/abs/2407.21783>
- Microsoft. (2023). Microsoft Presidio: Data protection and de-identification SDK. GitHub. <https://github.com/microsoft/presidio>
- Moritz, P., Nishihara, R., Wang, S., Tumanov, A., Liaw, R., Liang, E., Elibol, M., Yang, L., Paul, W., Jordan, M. I., & Stoica, I. (2018). Ray: A distributed framework for emerging AI applications. Proceedings of the 13th USENIX Symposium on Operating Systems Design and Implementation (OSDI), 561–577. <https://www.usenix.org/conference/osdi18/presentation/moritz>
- WekaIO. (2025). Inference at scale: Storage as the new AI battleground. <https://www.weka.io/resources/white-paper/ai-storage-inference/>
- European Parliament. (2024). Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). Official Journal of the European Union. https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=OJ:L_202401689
- Apache Software Foundation. (2024). Apache Parquet documentation. <https://parquet.apache.org/docs/>

